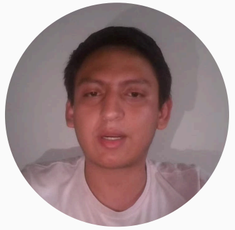
PROYECTO FINAL · ENTREGA 1



Detección de pagos y proveedores duplicados en las compras del Banco

Entendimiento de los datos de facturas para Procurement S2PA

María Paula Ospina - 202123208

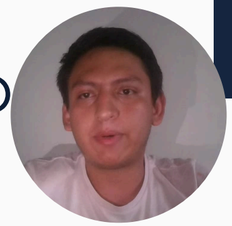
Mateo Bernal Bonil - 202510037

Andrés Camilo Beltrán Cordoba - 202511522

Jorge Aleks Fernando Acosta Villate - 202324675

EL PROBLEMA DE NEGOCIO

Las facturas se revisan a mano y casi siempre después del pago



El proceso va de la requisición a la orden de compra y su aprobación, luego llega la factura a SmartBuy (Coupa) por uno de cinco canales y termina en el pago. No existe una vista consolidada por proveedor ni un puntaje de riesgo, así que los pagos dobles solo aparecen cuando alguien los reporta.

11.168,6 M
CAD aprobados en facturas de 10.000 CAD o más, de junio de 2022 a julio de 2026

24,4%
del gasto está en proveedores registrados con más de una llave

43%
de los fraudes ocupacionales se descubre por denuncias y no por controles (ACFE, 2024)

QUIÉN SIENTE EL PROBLEMA

Analistas de S2PA
revisan por muestreo en Excel

Procurement Governance
se entera de los pagos dobles por reportes

Dirección de compras
negocia sin el gasto consolidado

Pregunta de negocio: ¿qué facturas aprobadas podrían ser un pago duplicado y cuánto del gasto está fragmentado entre llaves del mismo proveedor?

OBJETIVOS E INDICADORES

Objetivo: una vista confiable del gasto y una cola de casos

OBJETIVOS ESPECÍFICOS

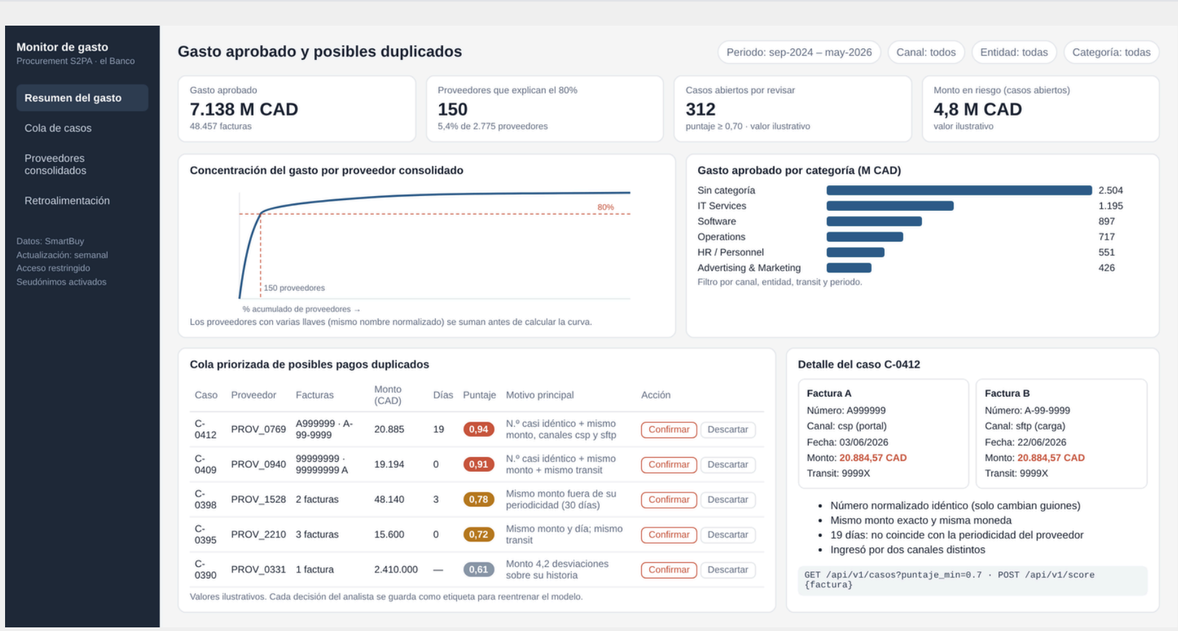
01	Caracterizar el gasto por proveedor, categoría, transit, canal y tiempo
02	Dar un puntaje de posible pago duplicado a cada factura aprobada
03	Agrupar proveedores duplicados y recalcular el gasto consolidado
04	Entregar un tablero y una API con la cola priorizada de casos
05	Validar con el Banco una muestra de los casos marcados

INDICADORES DE NEGOCIO

Indicador	Línea base	Meta
Gasto consolidado por proveedor	24,4% sin consolidar	100% revisado
Precisión de los 50 primeros casos	No existe	30% o más
Monto duplicado recuperado	120.379 CAD por confirmar	90% de lo confirmado
Cobertura de la revisión	Muestreo	100% semanal
Tiempo de detección	Después del pago	7 días o menos

PRODUCTO DE DATOS

Un modelo, una API y un tablero para revisar cada factura



Mockup del tablero. Los valores de la cola son ilustrativos.

01

Modelo
Reglas de duplicados aproximados y montos atípicos por IQR; luego, un modelo entrenado con etiquetas del Banco. Agrupa proveedores por Levenshtein.

02

API REST
Servicios de puntaje, de casos y de proveedores, para integrarse con SmartBuy.

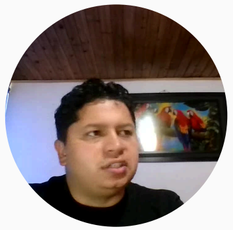
03

Tablero
Gasto consolidado, cola priorizada y registro de la decisión del analista, que se vuelve etiqueta.

> La decisión del analista cierra el ciclo: cada caso revisado es una etiqueta nueva para el modelo.

ÉTICA, HIPÓTESIS Y ENFOQUE ANALÍTICO

Hipótesis del análisis y privacidad desde el diseño



Ética y legal

- Seudónimos para empleados y proveedores, sin logins ni identificadores y con uso solo académico (Ley 1581 y PIPEDA)
- Repositorio privado, ya qué se tiene acuerdo de confidencialidad; el Banco lo revisa para evitar que un proveedor se reconozca
- Se habla de «posible duplicado», nunca de fraude, y toda alerta tiene revisión humana
- Modelo interpretable y monitoreado, según la Guideline E23 de OSFI

Hipótesis

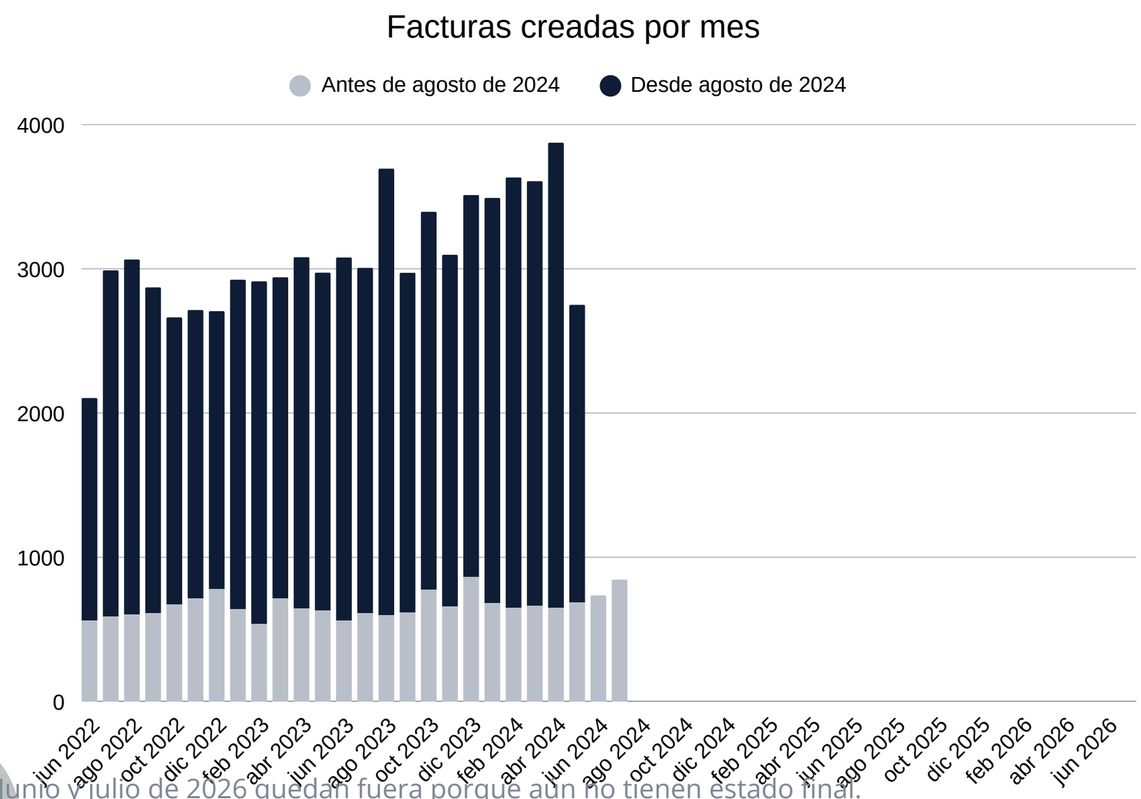
- **H1.** Los posibles duplicados se concentran en algunos canales de carga
- **H2.** Sin cadena de aprobación o con autoaprobación hay más candidatos a duplicado
- **H3.** Los proveedores nuevos o concentrados tienen más anomalías
- **H4.** Un monto por fuera de las cercas del IQR de su proveedor se asocia con más anulaciones

Calidad de datos > Perfil del gasto > Bivariado y multivariado > Pruebas de hipótesis > Modelo y validación

Métricas del modelo: proporción confirmada en los primeros k casos y proporción de duplicados reales encontrados, con su intervalo de confianza.

ENTENDIMIENTO DE LOS DATOS · PERIODO DE ANÁLISIS

Los años no son comparables: el proceso cambió en 2024



Junio y julio de 2026 quedan fuera porque aún no tienen estado final.

542 a 868

facturas por mes antes

1.922 a 3.219

facturas por mes después

0% a 37,7%

facturas cargadas por sftp

70% a 25%

facturas con contrato (aproximado)

Comparar años habría confundido un cambio de proceso con un cambio en el riesgo. Por eso la ventana es de septiembre de 2024 a mayo de 2026.

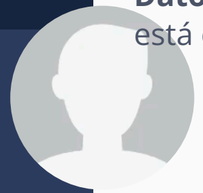
Ventana analítica: 51.429 facturas y 7.138 M CAD aprobados

ENTENDIMIENTO DE LOS DATOS · CALIDAD

Cada problema de calidad terminó en una decisión explícita

	DIMENSIÓN	HALLAZGO	DECISIÓN
01	Precisión	Una factura de 1.070 M CAD estaba en pesos colombianos marcada como CAD. Hay 75 montos extremos para su proveedor	Monto a nulo. 57 extremos verificados por recurrencia y 18 fuera de las correlaciones
02	Consistencia	El número de aprobadores está vacío en el 99,3% de las facturas anuladas porque se llena al aprobar	No se usa para explicar la anulación (fuga de información)
03	Unicidad	22 nombres de proveedor tienen varias llaves dentro de la misma entidad	Se agrupan por nombre normalizado y se validan con el Banco
04	Completitud	El 50,5% de las aprobadas no tiene cadena de aprobación; el 83,9% de ellas entró por el portal o cXML, que se aprueban en la orden de compra	Banderas por proceso, sin imputar. La regla de aprobación desde 10.000 CAD se valida con el Banco

Datos personales: nombres de empleados y proveedores seudonimizados (EMP y PROV), logins e identificadores eliminados. Ningún dato del Banco está en el repositorio.



HALLAZGO PRINCIPAL · POSIBLES DUPLICADOS

Hay facturas casi idénticas que pasan el control del sistema

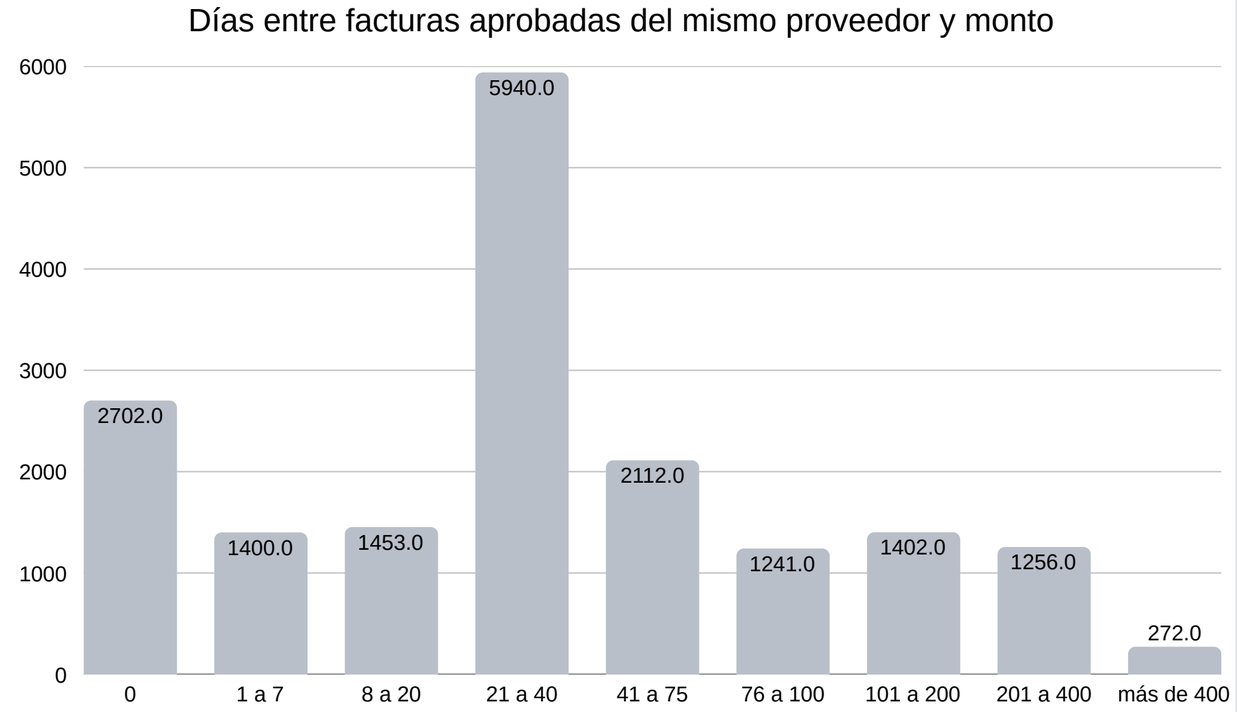
6 grupos

de facturas aprobadas con el mismo monto y un número que solo cambia en un signo, un espacio o un cero

120.379 CAD

que podrían haberse pagado dos veces

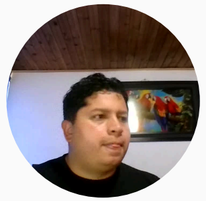
Además, 3.078 aprobadas (6,4%) repiten proveedor y monto en 7 días o tienen un número casi idéntico. Son candidatas, no duplicados confirmados.



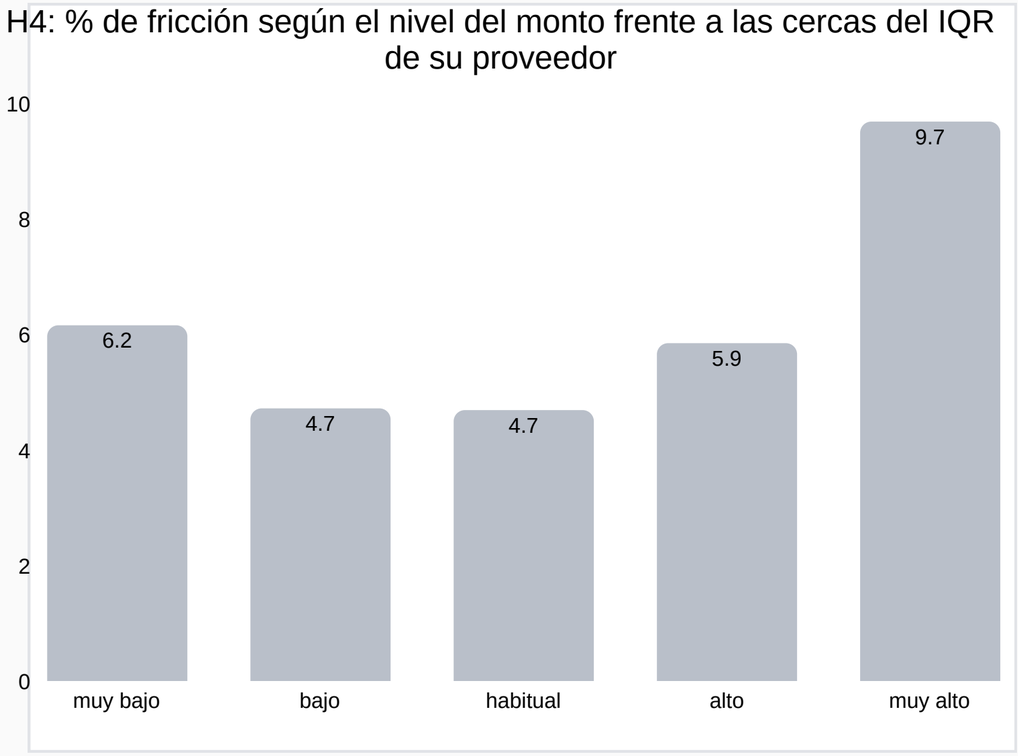
El pico de 21 a 40 días son cuotas mensuales legítimas. El modelo debe aprender la periodicidad de cada proveedor.

PRUEBAS DE HIPÓTESIS

Tres de las cuatro hipótesis se apoyan, al menos en parte



H	Resultado	Evidencia
H1	Se apoya	El portal concentra los candidatos (10,16%); V de Cramér 0,143
H2	En parte	Sin cadena de aprobación 5,02% frente a 3,22%; la autoaprobación tiene un efecto mínimo (V 0,021)
H3	No se apoya	Los proveedores nuevos tienen menos fricción, no más
H4	Se apoya	Monto sobre la cerca del IQR de su proveedor: 9,69% de fricción frente a 4,96%



En la regresión lineal, las facturas en CAD tienen 5,91 puntos porcentuales menos de fricción que las de otras monedas. Son asociaciones, no causas.

CONCLUSIONES Y PRÓXIMOS PASOS

Los datos alcanzan para la vista del gasto; para el modelo hacen falta etiquetas reales

Validar > **Completar datos** > **Modelar** > **Desplegar**

Validar	Completar datos	Modelar	Desplegar
Los 6 grupos y una muestra estratificada de 202 casos con el Banco	Niveles de aprobación, fecha de pago y maestro de proveedores	Variables por par de facturas, puntaje por reglas y modelo con las etiquetas	API REST y tablero con la cola de casos

LIMITACIONES

- No hay etiquetas de duplicado confirmado
- No hay fecha de pago ni tabla de niveles de aprobación
- La cadena de aprobación solo existe para facturas aprobadas
- Los grupos de proveedores dependen del nombre normalizado

> La muestra de 202 casos da un margen de error de 7 puntos porcentuales con 95% de confianza. Con esas etiquetas se puede pasar del puntaje por reglas a un modelo entrenado en la entrega 2.